

Step-wise RL for Multi-hop QA

selection-only RL의 한계 규명 → 추론을 LLM 안에 두는 후속

팀 구성

- A72051 박두산 (팀장)
- A72058 신세정 (팀원)

GitHub Page

- <https://github.com/doosanpark/RL-Multihop-RAG>

프로젝트 목적과 목표

이 프로젝트의 질문: "검색·답변 과정에 강화학습을 쓰면, 학습 없는 cosine 휴리스틱보다 나은 multi-hop RAG를 만들 수 있는가?"

프로젝트 목적 (Purpose)

Multi-hop QA에서 RL이 무엇을 어디까지 줄 수 있는지를 두 단계로 정직하게 검증한다.

- **Part 1:** frozen LLM 위 selector를 RL로 학습해 cosine 휴리스틱과 겨룬다.
- **Part 2:** LLM 자체를 SFT→GRPO RL로 파인튜닝(Search-R1)해 추론을 LLM 안에 둔다.

세부 목표 (Goals)

01

RL 적용·구현

Passage selection을 MDP로 정식화하고
REINFORCE+baseline을 구현
(CartPole 3-seed sanity 통과)

02

성능·전이 검증

학습 없는 cosine 휴리스틱 대비 in-domain 성능과 새 도메인 transfer 강건성을 3-seed로 측정

03

원인 규명

성능이 오르거나 떨어지는 원인을 reward hacking·상태 표현·hop 타입 관점에서 정량적으로 분석

전체 연구 프로세스

두 PART로 이어지는 연구 과정 — 실패를 진단하고, 그 진단에 근거해 방법을 바꾼다

PART 1 · 왜?

검색 단락 선택을 RL로 최적화하면 휴리스틱을 넘을까?

방법 frozen LLM + selector를 REINFORCE+baseline으로 학습

PART 1 · 발견

$0.355 < 0.370$

휴리스틱 못 넘음

전이 -24% 폭락 · 원인 = 추론 용량(capacity) 부재



추론 용량이 없다면 → 추론을 LLM 안에 넣자

PART 2 · 왜?

추론을 LLM 안에 두면 휴리스틱을 넘을까?

방법 Qwen LoRA를 SFT→GRPO로 파인튜닝 (Search-R1)

PART 2 · 발견

$0.469 > 0.370$

in-domain 돌파

단 이득은 comparison에 집중 · bridge 미해결 · 전이는 과적합

종합 통찰

추론을 LLM 안에 두면 in-domain은 이기지만, 도메인 전이는 학습 없는 휴리스틱에 진다 — RL의 효과와 한계를 3-seed로 규명

프로젝트 한눈에

문제

- Multi-hop QA에서 학습 없는 휴리스틱을 RL로 넘을 수 있는가?
- **selector**를 학습하는 길(PART 1)과 **LLM 자체**를 학습하는 길(PART 2)을 두 PART에 걸쳐 검증

방법

- **PART 1** frozen LLM 옆에 작은 selector(2-layer MLP)를 두고 REINFORCE+baseline으로 단락 선택을 학습
- **PART 2** LLM 자체를 LoRA로 SFT warmup → outcome F1 보상의 GRPO로 파인튜닝 (Search-R1)

핵심 결과

- **PART 1** selection-only RL은 cosine 휴리스틱(**0.370**)을 못 넘음 (**0.355**) · BC(지도학습) 0.335도 동급 → 병목은 정책 표현 용량
- **PART 2** 추론을 LLM 안에 두자 in-domain 돌파 (**0.469**). 단 도메인 전이에선 학습 없는 cosine 휴리스틱(**0.386**)이 강해 — “**학습효과 vs OOD 강건성**” 트레이드오프를 정량 규명

Part 1.

검색 단락 선택을 RL로 최적화하면 cosine 휴리스틱을 넘을까?


프로젝트 목적 (Purpose)

Multi-hop QA에서 RL이 무엇을 어디까지 줄 수 있는지를 두 단계로 정직하게 검증한다.

- Part 1: frozen LLM 위 selector를 RL로 학습해 cosine 휴리스틱과 겨룬다.
- **Part 2:** LLM 자체를 SFT→GRPO RL로 파인튜닝(Search-R1)해 추론을 LLM 안에 둔다.

강화학습(RL) 적용 타당성


기존 RAG · one-shot retrieval



질문과 직접 닮은 문서엔 강하지만,
표면적으로 닮지 않은 bridge evidence를 놓치기 쉽다.

vs

우리 문제 · sequential evidence selection



각 step에서 keep / drop / stop 결정 — 이전 선택이 다음 상태와 최종 답 품질에
영향을 준다.

State 질문 + keep한 단락 + 후보 상태

Action keep / drop / stop

Reward supporting fact 보상 + answer F1 final

핵심 Multi-hop RAG의 passage selection은 단순 검색이 아니라 좋은 evidence를 순차적으로 모으는 의사결정 문제 — 그래서 State / Action / Reward 로 정식화할 수 있다.

연구 동기과 기여

동기(문제 배경)

RAG는 일반적으로 질문-단락 유사도 기반의 top-k 검색으로 단락을 선택한다.

그러나 multi-hop 질문(예: "X를 작곡한 사람이 태어난 도시는?")에서는 정답에 필요한 2차 단락(bridge)이 원 질문과 직접 유사하지 않아 검색에서 누락될 수 있다.

본 연구는 이러한 단락 선택 과정을 순차적 의사결정 문제(MDP)로 정식화하고, 강화학습으로 최적화할 수 있는지 검증한다.

기여 (Contributions)

1

MDP 정식화 + step-wise reward 설계

supporting_facts에서 자동 생성되는 중간 보상 설계 (REINFORCE+baseline, CartPole 3-seed sanity 통과)

2

체계적 진단 분석

reward hacking 정량 포착 · 입력 표현↔일반화 규명 · 단일 seed 착시의 3-seed 반증 · REINFORCE 불안정성 대응

3

정직한 한계 규명

selection-only RL은 in-domain에서 cosine 휴리스틱과 동급, transfer에서 열세 — 원인을 bridge 분석·Search-R1 대비로 설명

문제 설정 — State / Action / Reward

1 에피소드 = HotpotQA 1 샘플. 후보 단락 N 개 (distractor 10 / 스포츠 8) 중 keep/drop을 순차 결정.


STATE	ACTION	REWARD
질문 + 현재까지 keep한 단락 집합 + 후보별 상태 + step t	{ keep p_i , drop p_i , stop & answer } 고정 크기 $2N+1$, 처리한 단락은 마스킹	즉시 step reward (supporting_facts 기반) + 종료 시 answer F1 기반 final reward

Transition keep/drop은 해당 단락을 처리됨 표시, stop은 종료. **Horizon** 최대 $T=10$ step. 종료 시 keep된 단락을 LLM에 넘겨 답 생성.

정책은 keep/drop/stop을 선택하고, 보상은 즉시(선택 품질) + 지연(답 품질) 두 층위로 학습 신호를 준다.

순차적 의사결정 루프 — Agent · Environment

- 매 step마다 에이전트는 keep, drop, stop 중 하나를 선택하고, 환경은 이에 따라 다음 상태와 보상을 반환한다.
- Stop을 선택하면 에피소드가 종료되며(Horizon $T \leq 10$), 최종적으로 keep된 단락만 LLM에 전달되어 답변을 생성한다.



핵심 보상은 즉시 **step reward**(선택 품질)와 종료 시 **final reward**(답 품질) 두 층위로 주어진다 — 다음 장에서 이 두 신호를 비대칭 step + 연속 F1 final로 설계한다.

비대칭 step reward + 연속 F1 final

Step reward (즉시)

이벤트	보상
정답 단락 keep	+0.20
정답 단락 drop (최대 페널티)	-0.30
노이즈 keep	-0.10
노이즈 drop	+0.05
stop	0

Final reward (연속, cliff 없음)

$$R_{\text{final}} = 2.0 \cdot F1(\text{answer}) - 0.1 \cdot t$$

$$\text{Return } G_0 = \sum \gamma^k r_k + \gamma^T R_{\text{final}}, \gamma = 0.99$$

설계 의도

비대칭(정답 drop을 가장 무겁게) → recall 보존.
연속 final reward → 정답 품질을 매끄럽게 유도.

step reward는 "좋은 선택"을 즉시, final reward는 "좋은 답"을 지연 보상 — 두 신호를 결합한다.

데이터셋 — 학습 / In-domain / Transfer

용도	데이터	규모
학습	HotpotQA distractor (train)	2,000 샘플
In-domain 평가	HotpotQA distractor (validation)	n = 200
Transfer 평가	스포츠 룰북 QA (자체 구축)	n = 350

Preprocessing

- supporting_facts 라벨 → step reward 자동 ground truth (추가 라벨링 불필요)
- 스포츠 룰북(공식 룰)을 HotpotQA 포맷으로 라벨링
- 인코딩: MiniLM-L6-v2 384d (freeze)

스포츠 룰북 350문항 (자체 구축)

bridge 305 / comparison 45 · 전부 hard
배구41 · 탁구50 · 배드민턴50 · 미식축구50
축구40 · 농구40 · 야구40 · 하키39
학습에 쓰지 않은 다른 분포 → H3(전이) 측정용

REINFORCE + Learned Baseline

핵심 업데이트

$$A_t = G_t - V_\phi(s_t) \quad (\text{advantage})$$

$$\nabla J = \sum \nabla \log \pi_\theta(a_t|s_t) \cdot A_t$$

$$\text{value loss} = \text{MSE}(V_\phi, G_t)$$

분산 감소 baseline · reward-to-go · advantage 정규화 · gradient clipping (max_norm = 1.0)

정책망 2-layer MLP (~200K params). hidden = (256, 128)

LLM Qwen2.5-0.5B-Instruct — freeze, 답 생성에만 사용

사전 검증. 본 학습 전 CartPole-v1로 알고리즘 sanity check — 3 seed 모두 avg(100ep) ≥ 195 통과 (242 / 185 / 157 episode).

학습 안정화를 위한 설계

BC warmup

문제

cold-start 시 정책이 "즉시 stop" 국소최적에 빠짐 (reward hacking)

해결

supporting_facts로 생성한 expert 정책(정답 keep → 노이즈 drop → stop)을 cross-entropy로 모방 학습한 뒤 RL을 시작함.

Lean state (32d)

문제

raw 임베딩(4639d) 입력은 train 과적합 → dev F1 0.19 (cosine 휴리스틱보다 낮음)

해결

일반화되는 per-candidate 신호로 축소 — $q_sim \cdot kept_sim \cdot 처리여부 \cdot step$. dev 0.29 → 0.35로 일반화 회복.

두 설계는 모두 진단 단계에서 확인된 실패 원인을 직접 수정한 것으로, 단순 하이퍼파라미터 조정이 아닌 원인 기반 개선에 해당함.

Hyperparameter & 평가 지표

항목	값
Optimizer / lr	Adam, lr = 1e-4
γ / hidden / grad_clip	0.99 / (256,128) / 1.0
weight_decay / batch	1e-4 / 8 episodes
BC warmup	1000 샘플 · bc_lr 1e-3 · 30 ep
episodes / ckpt	2,500 / dev-best 선택
Encoder / LLM	MiniLM-L6-v2 / Qwen2.5-0.5B (freeze)

평가 지표

answer_F1 (핵심) · exact_match
support_F1 (선택 품질) · avg_n_kept

신뢰도 확보

3 seed (42 / 123 / 7) 학습
→ mean $\pm$ std 신뢰구간
step vs sparse ablation 비교

하드웨어: RTX 4060 Ti 8GB · 모든 방법을 동일 frozen Qwen2.5-0.5B 위에서 공정 비교.

실험 설계 근거

frozen LLM, 모델 규모, 데이터 분할을 선택한 이유

1

LLM = Qwen2.5-0.5B-Instruct (freeze, 학습 안 함)

- 이 PART의 가설은 "selection을 RL로 최적화하면 cosine 휴리스틱을 넘는가" — LLM은 변수가 아닌 고정 환경.
- LLM은 episode 종료 시(stop_and_answer)에만 호출: question + keep된 단락 → 답 생성. 학습 중 gradient 안 흐름.
- 부수효과: 학습은 ~200K params MLP만 갱신 → 8GB GPU에서도 매우 가볍게.

2

Encoder = sentence-transformers MiniLM-L6-v2 (384d, freeze)

- 학습 없이 일반화된 의미 임베딩 — 이것이 곧 우리가 넘어야 할 "학습 없는 cosine 휴리스틱".
- state encoder와 baseline retriever 모두 동일 모델을 재사용 → 공정 비교를 위해 임베딩 공간 통일.

3

정책망 = 2-layer MLP, hidden (256, 128), 약 200K params

- 작게 잡은 이유: MDP의 진짜 병목이 state 표현인지 정책 capacity인지 분리하기 위함. 결과 "capacity 부족"이 진단으로 확정.

4

데이터 분할 (학습/in-domain/transfer)

- 학습: HotpotQA distractor train 2,000 샘플 (수렴엔 충분, 시간 절약).
- in-domain 평가: HotpotQA distractor validation n=200.
- transfer 평가: 자체 구축 스포츠 룰북 350문항 — 학습에 미사용 (H3 측정 전용).

5


하드웨어 = 로컬 RTX 4060 Ti 8GB · CUDA 12.1 · Python 3.11 venv

- 의존성 핀: numpy 1.26 / pyarrow 17 / pandas 2.3 / datasets 2.21 (Windows에서 검증된 조합).

In-domain (HotpotQA, n=200)

방법	answer F1	support F1	kept
Oracle (상한)	0.557	1.000	2.0
Naive RAG (cosine top-3)	0.370	0.582	3.0
use_all	0.367	0.340	9.9
Step-wise RL (제안)	0.355 ±.012	0.533 ±.005	2.0
Sparse RL	0.354 ±.002	0.512 ±.027	2.0
BC-only (지도학습)	0.335 ±.005	0.546	2.0
random (하한)	0.275	0.258	3.0


RL(0.355)이 학습 없는 cosine 휴리스틱(0.370)을 못 넘음. 단 단락을 2개만 keep해 cosine 휴리스틱(3개)과 비슷한 F1 — precision 이점. BC-only(0.335)도 RL과 동급 → 한 계는 RL 방식이 아니라 정책 표현 용량.



Transfer (스포츠 룰북, n=350)

방법	answer F1	support F1
Oracle (상한)	0.452	1.000
Naive RAG (cosine top-3)	0.386	0.666
use_all	0.369	0.400
Step-wise RL	0.270 ±.038	0.461
Sparse RL	0.267 ±.034	0.456
BC-only (지도학습)	0.265 ±.035	0.466
random	0.263	0.305

In-domain → Transfer 변화



핵심.

Naive(cosine)는 도메인이 바뀌어도 견고(+0.016). 반면 **학습된 RL은 -24% 폭락(0.355→0.270)** — 심지어 random(0.263) 수준. 학습 정책이 HotpotQA 분포에 특화돼 전이가 안 됨. BC-only도 -21%로 동일 하락 → OOD 취약성은 RL이 아닌 학습형 정책 공통의 성질.

학습곡선 & Hop 타입별 분석




Figure 1 · dev F1 (3 seed mean±std) — 두 곡선의 std 음영이 학습 내내 겹침 = 유의차 없음

Hop 타입별 (in-domain, seed 42)

방법	bridge	comparison
Naive (cosine)	0.350	0.435
Step-wise RL	0.316	0.448

RL이 이겨야 할 곳은 cosine 휴리스틱이 실패하는 bridge(multi-hop)인데
정작 bridge에서 RL이 cosine 휴리스틱보다 낮다 ($0.316 < 0.350$).

→ 정책이 multi-hop 추론(1차→2차 단락 연결)을 학습하지 못했다.

가설 검증 — 셋 다 지지되지 않음

H1

Step-wise >>
Sparse?

기각

- 3-seed 평균에서 answer F1은 사실상 동일함(0.355 vs 0.354).
- 단일 seed에서 관찰된 우위는 재현되지 않음.
- 반면 step reward는 support_F1 분산이 더 작아(± 0.005 vs ± 0.027), 선택 품질을 보다 일관되게 유지함.

H2

RL > Naive?

기각

- in-domain에서 RL(0.355) < cosine 휴리스틱(0.370). precision 이점은 있으나 절대 성능은 못 넘음.

H3

Transfer 가능?

부정

- 새 도메인에서 RL 성능이 24% 하락함.
- 이는 학습된 정책이 HotpotQA 분포에 특화되어 새로운 도메인으로 일반화되지 못했음을 시사함.

주요 시사점

1 Reward hacking 정량 포착

- BC 없이 학습하면 정책이 즉시 stop을 선택하는 reward hacking에 빠짐.
- 기대 reward(+0.198)가 실제 관측값(+0.20)과 일치했으며, BC warmup으로 이를 해결함.

2 입력 표현이 일반화를 좌우

- 고차원 raw 임베딩은 과적합을 유발함(dev 0.19).
- 반면 lean state(32d)는 일반화를 개선해 dev 0.35를 달성함.

3 단일 seed 착시 반증

- 단일 seed에서는 성능 향상이 있는 것처럼 보였지만, 3-seed 평균에서는 차이가 사라짐.
- 재현성 검증의 중요성을 확인함.

4 REINFORCE 불안정성

- 학습 후반에 성능이 다시 하락하는 현상이 나타남.
- 따라서 최고 성능 시점의 checkpoint를 저장하여 사용함.

Part 2.

추론을 LLM 안에 두면 cosine 휴리스틱을 넘을까?


프로젝트 목적 (Purpose)

Multi-hop QA에서 RL이 무엇을 어디까지 줄 수 있는지를 두 단계로 정직하게 검증한다.

- **Part 1:** frozen LLM 위 selector를 RL로 학습해 cosine 휴리스틱과 겨룬다.
- **Part 2:** LLM 자체를 SFT→GRPO RL로 파인튜닝(Search-R1)해 추론을 LLM 안에 둔다.

PART 1의 한계와 Search-R1의 출발점


PART 1 방식 · frozen LLM + 외부 selector



selector엔 multi-hop 추론 용량이 없어
학습 없는 cosine 휴리스틱을 못 넘음 ($0.355 < 0.370$).

VS

PART 2 방식 · LLM 내부 추론·검색 (Search-R1)



추론·검색을 LLM 안에서 수행(Search-R1) — 학습 대상이 selector가 아니라 LLM 자체.

Policy Qwen + LoRA · think→search→answer

Reward answer F1 + 0.1·format

GRPO G=5 group baseline + KL(참조 SFT)

핵심 PART 1의 병목은 selector의 추론 용량 부재 — 학습 대상을 LLM 자체로 옮겨 추론·검색을 LLM 안에서 수행하고, outcome F1 보상으로 **GRPO**로 최적화한다.

PART 1의 한계 → PART 2의 보완

PART 1의 결론이 곧 PART 2의 출발점 — 무엇을 보완하려 했는가

PART 1이 멈춘 지점

- RL(0.355)이 cosine 휴리스틱(0.370)을 못 넘음
- 이겨야 할 bridge(multi-hop)에서 오히려 더 낮음 ($0.316 < 0.35$)
- 새 도메인 transfer에서 -24% 폭락, cosine 휴리스틱은 견고

진단:

정책이 유사도 feature 위 작은 MLP라 multi-hop 추론을 학습하기에 표현력이 제한적이었을 가능성이 있음

.LLM은 freeze. → **multi-hop 추론 용량이 구조적으로 부재.**



PART 2가 바꾼 것

- 학습 대상을 selector에서 LLM으로 이동
- 추론을 LLM 내부에서 수행 (Search-R1: think→search→answer)
- Qwen LoRA를 SFT → GRPO를 적용하여 검색·추론 정책을 직접 학습

핵심:

같은 "supervised warmup → RL" 레시피를 **selector가 아니라 LLM에 적용.**

동일한 SFT→RL 학습 절차를 유지하되, 학습 대상을 selector가 아닌 LLM으로 변경함.

추론을 LLM 안으로 — Search-R1 방식 SFT→GRPO

배경.

- PART 1에서 frozen LLM 위에 selector를 두고 REINFORCE+baseline으로 학습했지만 RL 기반 selector는 cosine 휴리스틱을 넘지 못함.($0.355 < 0.370$).
- 우리는 이를 selector의 제한된 추론 용량 때문으로 해석했고, PART 1의 Future Work였던 Search-R1(SFT→GRPO)을 실제로 구현하여 이 가설을 검증하고자 함. PART 2의 목표는 추론을 LLM 내부로 옮겼을 때 성능이 개선되는지 확인하는 것임.

가설 (Hypotheses)

1

HA-1 · 추론 용량 가설

추론을 LLM 안에 두면(SFT search) 추론 없는 selector·cosine 휴리스틱을 in-domain에서 넘는다.

2

HA-2 · RL 추가이득

outcome F1 보상의 RL(GRPO)이 SFT 위에 추가 이득을 준다. 어떤 hop 타입에서 나타나는가?

3

HA-3 · 도메인 전이

파인튜닝된 search 정책의 도메인 전이는? 학습 없는 cosine 휴리스틱 대비 우열은 어떻게 되는가?

검색·추론을 LLM 안에서 — SFT warmup → GRPO

Qwen2.5-0.5B-Instruct를 LoRA($r=16$, $q/k/v/o$)로 파인튜닝함. 검색 결과는 별도 대화 턴이 아닌 동일 assistant 턴 내에 inline으로 주입되어 추론과 답변 생성에 활용됨.

PROTOCOL

- **1. Think** : 추론 계획 수립
- **2. Search** : 검색 질의 생성
- **3. Information** : 검색 결과 주입
- **4. Answer** : 최종 답변 생성
- (후보 풀 내 MiniLM Top-2 검색)

SFT WARMUP

- supporting_facts 기반 멀티홉 trace 생성
- think→search→answer 절차 학습
- cold-start 제거(val loss 0.113)

GRPO (RL)

- 질문당 $G=5$ rollout
- 보상:answer F1 + format
- KL 정규화로 학습 안정성 확보

핵심. “GRPO는 REINFORCE의 확장이고, value network 없이 분산을 줄인다.”

- GRPO는 REINFORCE에 group baseline과 KL 정규화를 결합한 방법으로, 강의에서 다룬 baseline-variance reduction 개념의 자연스러운 확장임. 질문당 $G=5$ 개의 rollout 평균을 baseline으로 사용하므로 value network가 필요 없으며, 8GB GPU 환경에서도 학습이 가능함.
- 또한 검색은 외부 검색 서버가 아닌 후보 풀(distractor 10) 내 query 기반 retrieval로 제한함. 이를 통해 검색 서버 구축 요소를 제거하고,검색·추론 정책 자체의 효과를 분석하는 데 집중함.
- 실험은 RTX 4060 Ti 8GB 환경에서 수행하였으며, Windows 환경 제약으로 vLLM 대신 HuggingFace generate를 사용함.

SFT를 통해 think→search→answer 프로토콜과 멀티홉 추론 절차를 LLM에 학습시킨 뒤, answer F1 기반의 GRPO를 적용하여 검색 질의 생성과 답변 추론 정책을 추가 최적화함.

8GB VRAM에서 LLM 자체를 학습하기 위한 선택들

- **Base LM = Qwen2.5-0.5B-Instruct (LoRA 학습 대상)**
 - 0.5B 이유: 8GB VRAM 제약. Full fine-tune은 메모리 초과 — LoRA로 학습 가능 부분만 한정.
 - Instruct 변종 선택: chat template과 system/user 분리, <think>/<search>/<answer> markup 출력 안정성이 base 대비 높음.
- **LoRA: r=16, target=q/k/v/o (attention만, FFN 제외)**
 - r=16: 학습 가능 ~2.16M params (전체의 0.44%). 학습 신호는 충분하면서 옵티마이저 상태(AdamW 2배)도 가볍게.
 - attention만 적용: FFN까지 포함하면 메모리 거의 2배. attention만으로도 본 실험엔 충분히 학습됨.
- **정밀도 & 메모리 = bf16 + gradient checkpointing**
 - bf16: 0.5B weights를 약 1GB로(fp32 대비 -50%). RTX 40 시리즈는 bf16 native 지원.
 - gradient checkpointing: activation 저장 대신 재계산 — backward 시 메모리 큰 폭 절감 (속도 약간 손해).
- **Batch: batch_size=2, grad_accum=8 → effective batch 16**
 - 작은 이유: logits 텐서 [B, T=768, V=152k]가 메모리를 폭식 — B=8은 OOM 발생.
 - grad_accum=8로 effective 16 유지하며 메모리 안정 학습.
- **Retriever = 동일 MiniLM-L6-v2 (PART 1과 공통)**
 - 후보 풀(distractor 10) 내 top-2 retrieve. 외부 인덱스/검색서버 미사용 — 검색 엔지니어링 제거하고 추론 학습에 집중.
- **평가 분할 (dev-test 누수 방지)**
 - dev = val[0:64] (체크포인트 선택용) · held-out = val[200:400] n=200 (최종 보고용, dev와 완전 disjoint).
 - RL 3 seed (42, 123, 7) 학습 → held-out에서 mean±std로 신뢰구간 보고.
- **Rollout = HuggingFace generate (~7s/개)**
 - vLLM은 Windows 네이티브 미지원이라 사용 불가. 도입 시 3-5배 가속 가능 (Future Work).

In-domain & Transfer — 메인 표 (3 seed mean $\pm$ std)

모델	in-domain F1	sports(transfer) F1
기존 frozen+cosine (폴백)	0.370	0.386
SFT search	0.434	0.299
RL (3-seed)	0.469 $\pm$.007	0.313 $\pm$.023

핵심 결과 요약


- Cold-start 환경에서 frozen-base F1이 0.006에 불과하여, SFT warmup의 필요성을 확인함.
- In-domain 성능은 cosine 휴리스틱 0.370 $\rightarrow$ SFT 0.434 $\rightarrow$ RL 0.469로 지속적으로 향상됨.
- RL의 추가 향상(+0.035)은 3-seed 평균에서 일관되게 재현되었으며(std=0.007), 단일 seed 효과가 아님을 확인함.)

Transfer — 정직한 음성/혼합 결과.


- Solution A(0.313)가 학습 없는 cosine 휴리스틱(0.386)에 미치지 못함.
- 다만 RL은 전이 환경에서도 SFT(0.299) 대비 향상을 보였으며(+0.014), comparison 유형에서는 강한 성능을 유지함.

결과 ② — 성능 향상의 원인 분석

핵심 — 성능 향상이 발생한 단계와 RL 효과의 분포를 분석함



- cosine 0.370 · selection-RL 0.355 → SFT 0.434 (+0.064) → SFT+GRPO 0.469 (+0.035)를 달성함. 추론을 LLM 내부로 옮긴 후 성능이 지속적으로 향상되었으며, 최종적으로 cosine 휴리스틱 기반 방법을 명확히 상회함.
- RL의 추가 향상(+0.035)은 3-seed 평균에서 일관되게 관찰되었으며(표준편차 0.007), 단일 seed에 의존한 결과가 아님을 확인함.



- RL 효과는 comparison 유형에 집중됨(+0.14, 0.428→0.568). 반면 bridge 유형의 향상은 +0.01에 그침.
- 이는 정답이 명확한 비교형(yes/no, 둘 중 택1) 질문에서는 F1 보상이 강한 학습 신호로 작용하는 반면, 개방형 bridge 질문은 부분 일치 기준이 모호하여 상대적으로 약한 학습 신호를 제공하기 때문으로 해석됨.

가설 검증 — 추론 용량 가설은 지지되나, RL 효과는 국소적임

HA-1

추론을 LLM 안에 두면?

지지

- In-domain 성능은 0.370(cosine)·0.355(selection-RL)에서 0.434(SFT), 0.469(RL)로 향상됨.
- 또한 cold-start 성능(0.006)을 고려할 때, SFT는 검색·추론 절차와 프로토콜을 효과적으로 학습시킨 것으로 해석됨.

HA-2

RL이 SFT 위 추가 이득?

부분

- RL은 SFT 대비 +0.035의 성능 향상을 보였으며, 3-seed 평균에서 일관되게 재현됨(std=0.007).
- 다만 효과는 comparison 유형(+0.14)에 집중되었고, bridge 유형의 향상은 +0.01에 그침.
- 정성 분석 결과, RL의 주요 기여는 retrieval 개선보다 질문 의도와 정답 토큰 간 정렬(alignment)의 개선으로 해석됨.

HA-3

도메인 전이는?

혼합

- Sports 도메인 전이 성능은 0.313으로 cosine 휴리스틱(0.386)에 미치지 못함.
- 이는 학습된 정책이 학습 도메인에 일부 특화되었음을 시사함.
- 다만 RL은 전이 환경에서도 SFT(0.299) 대비 +0.014의 향상을 보였으며, comparison 유형에서는 비교적 강한 전이 성능을 유지함. 결과적으로 in-domain 성능과 OOD 일반화 사이의 trade-off가 관찰됨.

종합 결론 — 두 접근법의 비교와 시사점

1 PART 1 · selection-only RL

- 정책 표현(2-layer MLP)은 cosine 휴리스틱(0.370)을 넘지 못함(0.355).
- 또한 새 도메인에서 24%의 성능 저하를 보여 cosine 휴리스틱보다 낮은 전이 성능을 보임(0.270 vs 0.386).
- 이러한 결과는 selector 기반 정책의 제한된 표현력이 multi-hop 추론의 병목으로 작용했을 가능성을 시사함.
- 지도학습(BC)만으로도 RL과 동급(0.335 vs 0.355) → 한계는 RL 방식이 아니라 정책 표현 용량.

2 PART 2 · Solution A

- 추론을 LLM 내부에 학습시킨 Search-R1은 in-domain 성능을 0.469까지 향상시켜 cosine 휴리스틱 기반 방법을 상회함.
- RL의 추가 효과는 comparison 유형에 집중되었으며, bridge 유형에서는 제한적으로 나타남.
- 다만 새 도메인에서는 성능이 0.313으로 감소하여, 성능 향상과 일반화 사이의 trade-off가 관찰됨.

결론

- 결론적으로, Multi-hop RAG에서 단순 선택 정책의 강화학습만으로는 cosine 휴리스틱을 넘기 어려웠으나, 추론 자체를 LLM 내부에 학습시켰을 때 의미 있는 성능 향상을 확인함.
- 즉, 본 프로젝트는 “무엇에 RL을 적용하느냐”가 “RL을 적용하느냐”보다 더 중요함을 보여줌.

한계와 향후 과제

한계

단일 base LM(Qwen2.5-0.5B, freeze)

→ 성능 천장이 LLM에 묶임 (oracle도 0.557)

영어 단일 언어 · transfer 도메인 1종(스포츠)

→ 전이 일반화 주장은 도메인 1개 기반

정책 표현 한계

→ 유사도 기반 소형 MLP는 multi-hop 추론을 학습하기에 표현력이 제한적이었음

REINFORCE high variance

→ 학습 후반 성능 변동이 커 dev-best checkpoint 선택에 의존함

RL 이득은 comparison에 집중

→ bridge(multi-hop 본질)는 +0.01로 사실상 미해결

향후 과제

① [검증 완료] Part1의 Future Work(Search-R1)를 구현하여 가설을 검증함

본 후속 연구에서 실제 실행: SFT→GRPO로 in-domain 0.469 — cosine 휴리스틱 돌파. 단 도메인 전이는 과적합.

② 전이 강건성 회복 — 차기 과제

1.5B+ 모델, 도메인 혼합 SFT, open-retrieval 환경에서 전이 성능을 재검토할 필요가 있음. 또한 format 보상 외에 검색 품질 및 근거-정답 일치 신호를 추가하여 bridge 유형의 성능 개선 가능성을 검증할 필요가 있음.

실험결과에 대한 생각

박두산

이번 프로젝트에서 가장 인상 깊었던 것은 당연히 지지될 거라 믿었던 가설이 실제로는 그렇지 않았다는 사실이다.

Multi-hop RAG는 단순 RAG로는 풀기 어려운 영역을 다루는 분야였고, 거기에 강화학습을 더하면 성능을 한 단계 더 끌어올릴 거라 기대했지만 실제로는 그렇지 않았다.

이 과정에서 강화학습이란 무엇이고 그것을 어떤 조건에서 적절히 써야 하는지를 깊이 고민하게 됐다.

앞으로 이런 시행착오 하나하나가 인공지능과 강화학습의 본질을 더 깊이 탐구하는 계기가 될 것이라 기대한다.

신세정

이번 프로젝트에서 가장 크게 배운 것은 RL이 항상 정답이 아니라는 점이다. 우리가 학습시킨 정책은 in-domain에서는 효과가 있었지만 새 도메인 전이에서는 학습 없는 cosine 휴리스틱에 오히려 뒤졌고, 그 과정에서 "점수를 올렸는가"보다 "왜 되고 왜 안 되는가"를 규명하는 일이 더 값지다는 것을 깨달았다.

GRPO 세팅과 RL 학습 동역학

1 GRPO 구성

질문당 G=5 rollout, group-normalized advantage(value network 불필요, 8GB 친화). 보상 = answer F1 + 0.1·format. KL(참조=SFT) 페널티 + gradient clipping. dev-best 체크포인트 (val[0:64] greedy F1)로 peak 보존.

2 보수적 RL vs 공격적 RL

보수적(lr 1e-5, KL 0.05)은 평평(dev 0.418≈SFT, KL~0.01로 정책 거의 안 움직임). 공격적(lr 3e-5, KL 0.01)에서 비로소 이득 — RL 하이퍼파라미터가 관건.

3 improve → peak → drift

dev F1은 개선→정점→후반 drift 패턴(seed42 peak 0.507@step80). seed7은 step100에 dev 0.354·search 1.2(후반 평균 ≈ 1.4)로 포맷 붕괴 — dev-best가 붕괴 직전 peak 보존.

4 reward hacking 미관측

전 구간 format 안정(has_answer≈1.0, 평균 2회 검색). 보상↑·F1 평평식 reward hacking은 관측되지 않음.

Per-seed 결과 · 하이퍼파라미터 · 재현

항목	값
in-domain F1 (seed 42/123/7)	0.466 / 0.479 / 0.463
sports F1 (seed 42/123/7)	0.282 / 0.338 / 0.317
SFT (LoRA)	$r=16$ (q/k/v/o) · bf16 · val loss 0.113
RL (GRPO)	$G=5$ · lr $3e-5$ · KL 0.01 · 100 steps
SFT trace	train 4,000 / val 400
Base / Encoder	Qwen2.5-0.5B-Instruct / MiniLM-L6-v2

SFT trace 생성

supporting_facts gold title을 질문 단어겹침 순 정렬
 → 멀티홉 trace 자동 생성 (예: Oberoi family → The Oberoi Group → Delhi → 답)

재현 (Reproduction)

src/sol_a/ · build_sft_data, sft_train,
 search_env, reward_a, grpo_train, eval_a
 RL: grpo_train --steps 100 --lr 3e-5 --kl-coef 0.01

in-domain = HotpotQA val[200:400] $n=200$ (dev와 disjoint) · sports = 350 문항 전체 · 모두 held-out, 3 seed mean±std.

팀 기여

팀 기여 분담

박두산 (팀장)

- 연구 기획, 프레임워크·환경·알고리즘 구현, 본 학습, 보고서

신세정 (팀원)

- 연구 기획, 스포츠 룰북 350문항 구축, 결과 재현 평가, PPT 제작

Github 링크

github.com/doosanpark/RL-Multihop-RAG

참고자료

RAG-RL: Advancing Retrieval-Augmented Generation via RL and Curriculum Learning